

AI Indoor Positioning

Team #1

b04303128 經濟四 吳海韜

b04705001 資工四 陳約廷

b05902093 資工三 顏睿楠

b03901056 電機四 孫凡耕

b05202043 物理三 呂佳軒

b06902021 資工二 吳聖福

(貢獻度平均各 1/6)

1 Abstract

這次 Final Project 我們要實作一個基於 Fingerprinting 的 AI 室內定位系統。希望透過監聽模式捕捉空氣中的封包，藉由訊號強度和時間推測某個 MAC Address 裝置在空間中的位置。

2 Methodology


對這個問題我們選擇了使用 Raspberry Pi 來作為監聽器材。選擇使用 R-Pi 的原因是因為其成本較低，如果在實際應用上需要擴大規模的話是相對容易的，同時在環境的部署上比較便利。另外我們使用監聽模式來觀察封包流量而不是主動連線，因此攔截到的大量封包中可能只有一小部分是真實處在我們監聽目標之中的。這也會是這次實驗裡的挑戰。

2.1 Difficulties & Workaround

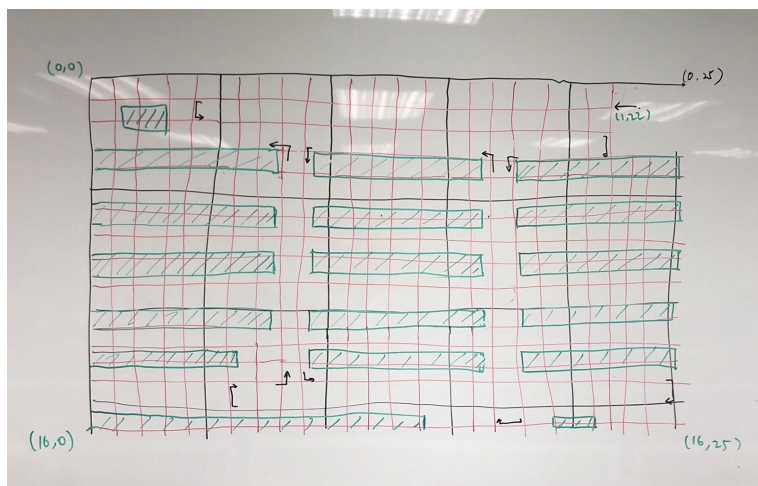

在為 R-Pi 安裝監聽模式的時候，碰到了一些軟體的困難，對這些困難我們做了相對應的改變，但仍然維持定位系統的完整性。首先是一台 R-Pi 無法同時監聽封包與將封包資料傳送給資料伺服器，因此我們後來將 R-Pi 的數量增加一倍，將 R-Pi 兩兩成對並用網路線互相連接。使一台作為另一台的 DHCP 並提供通往資料伺服器的網路。

另外在 802.11 2.4Ghz 無線網路封包協定中有 14 個頻道中，而在監聽模式中切換封包會有大量的「掉包」導致無法順利監聽，而且在頻道切換時一直發生網卡無法運作的關係，最後在這次實驗中我們將監聽的頻道固定。這並不影響我們這次實驗的完整性，如果想要監聽所有頻道的話只要依頻道倍增 R-Pi 數量即可。

2.2 Set-up



我們實驗的位置是德田 R204 教室，我們將 R-Pi 安裝在教室的 6 個角落，分佈如上圖。成對的 R-Pi 透過我們設定實驗二提供的網卡和實驗三的 AP 來以特定頻道傳送封包，其中一個固定在監聽channel（這裡是選channel 7）、另一個固定在非監聽channel用作傳送資料用。






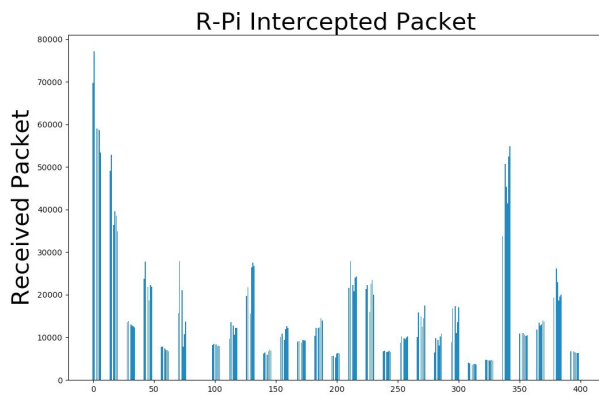
上圖是我們定義教室為 16x25 的二維空間。我們以時間、封包接收裝置（R-Pi）、發送封包裝置（手機）、以及封包訊號強度（RSSI）來對搜集到的封包做標記。接下來嘗試對搜集到的資料做模型訓練，以訓練出來的模型作為是室內定位系統的預測模型。

3 Experiment

3.1 Generate Training Data

在收集標籤資料時，我們記下每個組員手機的 MAC Address 並使得手機連接架設的固定頻道 AP，讓手機下載檔案並且在每個座標點上固定 5 秒，並且將手機垂直搖擺來增加資料點上封包資料的多樣性。

我們將六個點的 R-Pi 所收集到的封包數量作圖，發現封包數量是相近的，這表示我們在搜集點的搜集能力是相近的。另外我們分別把搜集點的資訊用散佈圖來表示時，可以發現說封包的強度確實是有一定的 Pattern，並且可以辨識出封包搜集點（R-Pi，圖中黃點）的位置。這樣的 Embedded Pattern 正是我們想要透過機器學習方法時希望抓到的。



3.2 Learning Model

a. Random Forest (隨機森林)

- 隨機森林是由多個decision tree (決策樹) 組合而成，進而以ensemble learning (集成學習) 增強整體的表現，最終整個模型的輸出就是所有決策樹輸出的平均值。隨機森林在多數的中小型分類或迴歸問題都有很不錯的表現，又因為計算需求較低，常常拿來當作一個不錯的基準模型。
- 輸入：目標裝置一段時間內來自6個接受器封包的訊號強度 (db) 取平均

b. Multilayer Perceptron (MLP, 多層感知器)

- 多層感知器 (Multilayer Perceptron, MLP) 是一個人工神經網路 (artificial neural network) 從輸入到輸出是一個有向圖，由輸入的維度一層一層映射到輸出，每一層都全連接到下一層，每個節點都有一個非線性的激活函數 (activation function)。多層感知器是把多個感知器疊起來，可以達到更好的表現，尤其對於高度非線性的資料。模型使用反向傳播算法 (backward propagation) 的監督學習 (supervised learning) 方法來訓練。
- 輸入：目標裝置一段時間內來自6個接受器封包的訊號強度 (db) 取平均

c. Self Attention

- 在自然語言處理中常用 Attention 這種 deep learning 方法來處理一段文字序列的上下文關係，對同一段序列用自己當 key/value 就是 Self Attention。在室內定位這個問題中，輸入是一段封包串流，對特定 MAC address 輸出它預測的座標。我們希望嘗試一種可以同時

處理「是目標 MAC 封包」和「背景封包」（不是目標 MAC）這兩種資料的模型，期待它可能透過學習 attention score 來把一部分權重分給其他作為參考用的背景封包，來提升效能。

- 輸入：每 8 筆封包當成一個 window 輸入，每筆封包輸入時間 (秒)、是不是目標封包 (0/1)、訊號強度 (db)

所有模型的輸出皆為我們定義的教室 X, Y 座標，和真實座標算 Mean Square Error

3.3 Model Performance

Random Forest

在 training 上 fit 的很好，但在 testing set 上表現跟樸素的 linear regression 上相似，甚至穩定度還低了一些。MSE 在 X, Y 軸分別在 3 跟 10 左右，換算成誤差距離大約是 2 公尺。

Multilayer Perceptron


採用兩層大小為 100 的 hidden layer，在 training set 和 testing set 上的表現相近，而且有明顯的比 linear regression 好。MSE 在 X, Y 軸分別在 1.5 和 5.5 附近，換算成誤差距離大約是 1.6 公尺，多次訓練下來的結果也很穩定。

Self Attention

在 testing set 上的預測結果和前兩個模型類似，在 X 軸（教室較短的方向）上預測很準，MSE 主要都來自 Y 軸。但是我們做的結果這個 model 表現相較之下並不好，MSE 在 X, Y 軸分別是 0.4194 和 18.8332，換算成誤差距離大約 2.63 公尺。Deep Learning Model 模型複雜、表現對模型架構很敏感，可能會需要更多硬體資源去嘗試不同的建模架構。

4 Result & Conclusion

4.1 Result



上圖是我們將定位結果發送到web server上顯示的結果，畫面中包含六台定位用的 R-Pi 1~6，以及有在 channel 7 發送封包裝置的 MAC Address。

为了更好地展示定位的預測結果，我們在204教室錄製了實況影片：

（系統只顯示PI板和我們展示的目標裝置）

- 真人移動畫面：

<https://drive.google.com/file/d/18-mDR5kHxNb2jr1s9p1rq-W-xQKB7nRh/view?usp=sharing>

- 快轉版系統畫面：

<https://drive.google.com/file/d/1WmDKpX84ih-3DwxupGROjc8xs6LDGd2l/view?usp=sharing>

4.2 Conclusion

我們這次的Final Project在教室內建構了一個室內定位系統，基於 Raspberry Pi 監聽模式得到的封包，加上運用AI模型來預測裝置位置。整體而言這是一個規模較小、屬於實驗性質的project，而如果要拓展到大規模應用，我們認為這個實驗中未來值得研究和改進的問題有：

1. 訊號接收器擺放位置：我們實驗時擺放Pi版的想法是希望將6個點盡量散佈在教室角落，但是實測結果是X軸（教室形狀較短的一邊）精準度很好、Y軸精準度相對表現不

佳。這部分可能需要進一步實測擺放方法和系統精準度的關係，進而做出更好的位置規劃。

2. Z 軸精準度：這次實驗中我們並沒有將高度列入模型考慮，而是透過收集資料時上下晃動手機裝置（詳見3.1節），期待 AI 模型能學會整合來自不同Z軸的訊號。我們這次將Pi版固定擺在教室有桌子的地方，也就是和人活動範圍差不多的高度。若要拓展系統規模的話，很可能會需要把訊號接收裝置放在天花板或其他高度，這樣就會需要在模型中考慮Z軸的影響。
3. 可變數量的訊號接收器：我們這次建模是假設 6 台 Pi 版位置皆不動，一台裝置在特定時刻發送的封包強度可以取平均用 6 維向量表示。如果收集資料或測試期間有任何裝置延遲或壞掉的話，都會大大影響預測準確度。這部分可以在 AI 模型方面設計成同時考慮訊號接收器的座標，這樣子可能有助於將系統擴展到定位空間更大、裝置更多的情形。